

# Cheatsheet für umerik

Paul Brinkmeier

12. Februar 2020

# Inhaltsverzeichnis

<b>1</b>	<b>Interpolation und Approximation</b>	<b>3</b>
1.1	Polynominterpolation . . . . .	3
1.2	Kubische Spline-Interpolation . . . . .	5
<b>2</b>	<b>Numerische Integration</b>	<b>5</b>
2.1	Quadraturformeln . . . . .	5
2.1.1	Ordnung von QF . . . . .	6
2.1.2	Symmetrische QF . . . . .	6
<b>3</b>	<b>Eigenwertprobleme</b>	<b>7</b>
3.1	Vektoriteration . . . . .	7
3.1.1	Inverse Vektoriteration . . . . .	7
<b>4</b>	<b>Iterative Verfahren von LGS</b>	<b>7</b>
4.1	Allgemeine lineare Iteration . . . . .	8
4.2	Beispiele für iterative Verfahren . . . . .	8
4.2.1	Jacobi-Verfahren . . . . .	8
4.2.2	Gauß-Seidel-Verfahren . . . . .	8
4.2.3	Unvollständige LR-Zerlegung . . . . .	8
4.3	Konvergenz von Jacobi- und Gauß-Seidel-Verfahren . . . . .	8
4.4	Algorithmus . . . . .	9
<b>5</b>	<b>Grundwissen</b>	<b>9</b>
5.1	Matrizen . . . . .	9
5.1.1	Symmetrische Matrizen . . . . .	9
5.1.2	Reguläre Matrizen . . . . .	9
5.1.3	Orthogonale Matrizen . . . . .	9
5.1.4	Matrixnormen . . . . .	9
5.1.5	Eigenwerte . . . . .	10

# 1 Interpolation und Approximation

**Weierstraßscher Approximationssatz** Sei  $f : [a, b] \rightarrow \mathbb{R}$  stetig. Dann gilt:

$$\forall \epsilon > 0 : \exists N \in \mathbb{N}, p \in \mathbb{P}^N : \max_{x \in [a, b]} |f(x) - p(x)| \leq \epsilon \quad (1)$$

## 1.1 Polynominterpolation

**Lagrange-Polynome** Das  $n$ -te Lagrange-Polynom zu  $N + 1$  Stützpunkten  $f_n(x) = f(x_n)$  ist gegeben durch:

$$L_n(x) = \prod_{m=0, m \neq n}^N \frac{x - x_m}{x_n - x_m} \quad (2)$$

$f(x)$  lässt sich dann interpolieren durch  $p(x)$  mit:

$$p(x) = \sum_{n=0}^N f_n L_n(x) \quad (3)$$

- Für  $f_n = 0$  muss man  $L_n$  also gar nicht berechnen.
- Ein Lagrange-Polynom hat immer den Grad  $N - 1$ .
- Lagrange-Interpolation ist für hohe  $N$  schlecht konditioniert und liegt außerdem in  $O(n)$ .

## Newton-Darstellung

$$p_{0,N}(x) = a_0 + a_1(x - x_0) + a_2(x - x_0)(x - x_1) + \dots + a_N \prod_{m=0}^{N-1} (x - x_m) \quad (4)$$

- Lässt einfach durch das Horner-Schema auswerten.
- $p_{0,N}(x) = p_{0,N-1}(x) + a_N w_N(x)$  mit

$$w_n(x) = \prod_{m=0}^{n-1} (x - x_m) \quad (5)$$

## Naive Koeffizientenbestimmung

$$f_0 = p(x_0) = a_0 \quad (6)$$

$$f_1 = p(x_1) = a_0 + (x_1 - x_0)a_1 \quad (7)$$

$$f_2 = p(x_2) = a_0 + (x_2 - x_0)a_1 + (x_2 - x_1)a_2 \quad (8)$$

- Problem:  $2n$  Additionen,  $2(n - 1)$  Multiplikationen, 1 Division für  $a_n$ .
- $\rightsquigarrow$  Insgesamt  $N(N + 1)$  Additionen,  $N(N - 1)$  Multiplikationen,  $N$  Divisionen.

## Lemma von Aitken

$$p_{n,k}(x) = \frac{(x_n - x)p_{n+1,k}(x) - (x_k - x)p_{n,k-1}(x)}{x_n - x_k} \quad (9)$$

### Dividierte Differenzen

$$f_{n,k} = \begin{cases} f_n & n = k \\ \frac{f_{n,k-1} - f_{n+1,k}}{x_n - x_k} & \text{sonst} \end{cases} \quad (10)$$

- $\frac{N(N+1)}{2}$  Divisionen
- $N(N+1)$  Additionen
- $p(x) = \sum_{m=0}^N f_{0,m} w_m(x)$

**Lebesgue-Konstante** Bezüglich der Stützstellen  $x_0, \dots, x_N$ :

$$\Lambda_N = \max_{x \in [a,b]} \sum_{n=0}^N |L_n(x)| \quad (11)$$

- $\Lambda_N$  ist nur von der relativen Lage der Stützstellen zueinander abhängig.

**Interpolationsfehler** Der maximale Interpolationsfehler eines Interpolationspolynoms  $p(x)$  zu  $f(x)$  mit  $N+1$  Stützstellen ( $x_0$  bis  $x_N$ ) ist:

$$\max_{x \in [a,b]} |f(x) - p(x)| \leq \max_{x \in [a,b]} |w_{N+1}(x)| \frac{\max_{x \in [a,b]} |f^{(N+1)}(x)|}{(N+1)!} \quad (12)$$

**Optimale (Tschebyscheff-) Stützstellen** Wählt man die  $N+1$  Stützstellen  $x_n$  genau als die Nullstellen des Tschebyscheff-Polynoms  $T_{N+1}(x)$ , wobei

$$T_0(x) = 1 \quad (13)$$

$$T_1(x) = x \quad (14)$$

$$T_{n+1}(x) = 2x \cdot T_n(x) - T_{n-1}(x) \quad (15)$$

$$T_n(x) = \cos(n \cdot \arccos x) \quad (16)$$

$$T_n(\cos(\frac{2n+1}{2N+2}\pi)) = 0 \quad (17)$$

so wird  $\max_{x \in [-1,1]} |w_{N+1}(x)|$  minimal, und zwar  $2^{-N}$ . Mit mehr Stützstellen sinkt also der Fehler.

Es gilt:

- $\forall x \in \mathbb{R} : |T_N(x)| \leq 1$
- $\deg(T_N) = N$
- $\langle T_0, \dots, T_N \rangle = \mathbb{P}^N$  (die  $T_n$  bilden 1 Basis von  $\mathbb{P}^N$ )
- $T_N$  hat  $N$  verschiedene reelle Nullstellen  $x_n$  mit  $x_n \in [-1, 1]$

### Tschebyscheff-Darstellung

$$p(x) = \frac{c_0}{2} + \sum_{n=1}^N c_n T_n(x) \quad (18)$$

- Tschebyscheff-Darstellung ist eindeutig.
- Berechnung von  $c_n$  im Fall  $N+1 = 2^k$ :  $O(N * \log N)$

**Clenshaw-Algorithmus** Sei  $p(x)$  gegeben als

$$p(x) = \frac{c_0}{2} + \sum_{n=1}^N c_n T_n(x) \quad (19)$$

Dann lässt sich  $p(x)$  folgendermaßen an der Stelle  $x$  auswerten:

$$d_{N+2} = 0 \quad (20)$$

$$d_{N+1} = 0 \quad (21)$$

$$d_n = c_n + 2xd_{n+1} - d_{n+2} \quad (22)$$

$$p(x) = \frac{1}{2}(d_0 - d_2) \quad (23)$$

- $2N$  Additionen,  $N + 2$  Multiplikationen

## 1.2 Kubische Spline-Interpolation

Seien  $(x_k, y_k)$  Stützstellen für  $k \in \{0, \dots, N\}$  mit

$$a = x_0 < x_1 < \dots < x_N = b \quad (24)$$

Ziel: Finde  $s(x)$  mit

- Interpolation:  $s(x_n) = y_n$
- Glattheit:  $s$  zweimal stetig diff'bar und

$$\int_a^b |s''(x)|^2 dx \quad (25)$$

minimal. Vorgehen:

$$s(x) = \begin{cases} s_1(x) & x \in [x_0, x_1] \\ s_2(x) & x \in [x_1, x_2] \\ \vdots & \\ s_N(x) & x \in [x_{N-1}, x_N] \end{cases} \quad (26)$$

Wobei aus 25 folgen muss:

$$s'_n(x_n) = s'_{n+1}(x_n) \quad (27)$$

$$s''_n(x_n) = s''_{n+1}(x_n) \quad (28)$$

## 2 Numerische Integration

### 2.1 Quadraturformeln

Allgemeine Darstellung

$$\int_a^b f(x) dx \approx \sum_{k=1}^s b_k f(a + c_k(b - a)) \quad (29)$$

$b_k$  nennt man Gewichte,  $c_k$  Knoten der Formel. Typischerweise:  $b_k, c_k \in [0, 1]$ .

- Rechteckregel:  $s = 1, (1, 0)$

- Mittelpunkregel:  $s = 1, (1, \frac{1}{2})$
- Trapezregel:  $s = 2, (\frac{1}{2}, 0), (\frac{1}{2}, 1)$
- Simpsonregel:  $s = 3, (\frac{1}{6}, 0), (\frac{4}{6}, \frac{1}{2}), (\frac{1}{6}, 1)$

Ein paar Fakten zu QF:

- Eine QF ist durch die Gewichte  $b_1, \dots, b_s$  und Knoten  $c_1 < \dots < c_s$  eindeutig bestimmt.

### 2.1.1 Ordnung von QF

Besitzt eine Quadraturformel die Ordnung  $p$ , so gilt liefert sie für alle  $f \in \mathbb{P}_{p-1}$  den exakten Wert des Riemann-Integrals

$$\int_a^b f(x) dx \quad (30)$$

Eine QF besitzt genau dann die Ordnung  $p$ , wenn für alle  $q \in \{1, \dots, p\} \subset \mathbb{N}$ , aber nicht mehr für  $q = p + 1$ , gilt:

$$\sum_{k=1}^s b_k c_k^{q-1} = \frac{1}{q} \quad (31)$$

### 2.1.2 Symmetrische QF

Eine QF heißt symmetrisch, falls gilt:

$$c_k = 1 - c_{s+1-k} \quad (32)$$

$$b_k = b_{s+1-k} \quad (33)$$

D.h. die Knoten sind symmetrisch um  $\frac{1}{2}$  angeordnet und die Gewichte sind symmetrisch verteilt.

- Symmetrische QF besitzen immer eine gerade Ordnung.

**Gauß-Quadraturformeln** Es existiert eine eindeutige Quadraturformel der Ordnung  $2s$ . Sie ist gegeben durch

$$c_k = \frac{1}{2}(1 + \gamma_k) \quad (34)$$

für  $k \in \{1, \dots, s\}$ , wobei die  $\gamma_k$  die Nullstellen des Legendre-Polynoms vom Grad  $s$  sind. Die Gewichte sind dann eindeutig bestimmt durch

$$b_k = \int_0^1 L_k(x) dx \quad (35)$$

Dabei ist  $L_k$  das  $k$ -te Legendre-Polynom, bspw.:

$$L_0(x) = 1 \quad (36)$$

$$L_1(x) = x \quad (37)$$

$$L_2(x) = \frac{1}{2}(3x^2 - 1) \quad (38)$$

- Gauß-Quadraturformeln sind monoton.

### 3 Eigenwertprobleme

Grundlegendes Problem: berechne Eigenwerte  $\lambda$  zu Eigenvektoren  $v$  einer quadratischen Matrix. Anwendungen: bspw. Eigenschwingung einer Membran, spektrale Bisektion.

**EW-EV-Gleichung** Sei  $A \in \mathbb{R}^{N \times N}$ . Dann heißen  $v \in \mathbb{R}^N \setminus \{0\}$  Eigenvektor und  $\lambda \in \mathbb{R}$  dazugehöriger Eigenwert von  $A$ , gdw.:

$$Av = \lambda v \quad (39)$$

Die „Wirkungsweise“ von  $A$  auf  $v$  ist also einfach zu verstehen (Stauchung/Streckung).

- $A$  hat EW  $\Leftrightarrow A$  ist singulär  $\Leftrightarrow \exists \lambda \in \mathbb{R} : \det(A - \lambda I_N) = 0$ .
- $\det(A - \lambda I_N)$  ist ein Polynom in  $\lambda$ , genannt charakteristisches Polynom von  $A$ .
- Aber: EW nicht wie bisher über c.P. berechnen, da schlecht konditioniert.

**Konditionszahl** Seien  $u, v \in \mathbb{R}^N$  normiert,  $Av = \lambda v$ ,  $u^\top A = u^\top \lambda$  ( $\Leftrightarrow A^\top u = \lambda u$ ). Dann heißt

$$\frac{1}{|u^\top v|} \quad (40)$$

die Konditionszahl von  $\lambda$ .

- $\frac{1}{|u^\top v|} \stackrel{(\text{CSU})}{\geq} \frac{1}{\|u\|_2 \|v\|_2} = 1$

Merke: Für  $A = A^\top$  gilt:  $u \in \{v, -v\}$ , d.h.

$$\frac{1}{|v^\top v|} = 1 \quad (41)$$

Symmetrische Matrizen sind also perfekt konditioniert.

#### 3.1 Vektoriteration

##### 3.1.1 Inverse Vektoriteration

$$Av = \lambda v \Leftrightarrow v = \lambda A^{-1}v \Leftrightarrow A^{-1}v = \frac{1}{\lambda}v \quad (42)$$

$\rightsquigarrow$  EV von  $A$  und  $A^{-1}$  sind identisch,  $\text{spec}(A^{-1}) = \frac{1}{\text{spec}(A)}$ .

### 4 Iterative Verfahren von LGS

Löse  $Ax = b$ , wobei

- $N$  sehr groß,
- $A$  dünn besetzt
- und/oder keine exakte Lösung nötig ist.

(Beispielsweise spektrale Bisektion).

Direkte Verfahren (LR, Cholesky, QR) sind hier ungeeignet, da sie aufwändig sind und „fill-in“ aufweisen, d.h. die Zerlegungsmatrizen sind (fast) voll besetzt, selbst wenn  $A$  dünn besetzt ist.

Alternative: Iterative Verfahren.

## 4.1 Allgemeine lineare Iteration

Seien  $A$ , „Vorkonditionierer“  $B$  regulär, idealerweise mit

$$\text{cond}(B^{-1}A) \stackrel{\text{viel}}{<} \text{cond}(A) \quad (43)$$

Dann gilt:

$$Ax = b \Leftrightarrow B^{-1}Ax = B^{-1}b \Leftrightarrow x = (I_N - B^{-1}A)x + B^{-1}b = x + B^{-1}(b - Ax) \quad (44)$$

Solche Gleichungen nennt man Fixpunktgleichungen.

**Fixpunktiteration** Eine solche Fixpunktgleichung kann durch eine Fixpunktiteration gelöst werden, wenn

$$\rho(I_N - B^{-1}A) < 1 \quad (45)$$

mit dem Spektralradius  $\rho(M) = \max |\text{spec}(M)|$ . Ausgehend von einem Startwert  $x^0 \in \mathbb{R}^N$  berechne für  $k = 0, 1, \dots$ :

$$x^{k+1} = x^k + B^{-1}r^k \quad (46)$$

mit dem Residuum  $r^k = b - Ax^k$ . Nach der Bedingung ist  $A$  regulär und die Fixpunktiteration konvergiert linear gegen eine eindeutige Lösung  $x_*$  von  $Ax = b$ .

## 4.2 Beispiele für iterative Verfahren

Zerlege  $A = L + D + R$ , wobei  $L$  eine *strikte* untere Dreiecksmatrix,  $R$  eine *strikte* obere Dreiecksmatrix und entsprechend  $D$  eine Diagonalmatrix ist.

### 4.2.1 Jacobi-Verfahren

Wähle  $B = D$ .

- Auch Gesamtschrittverfahren genannt.
- Einfach parallelisierbar wegen komponentenweiser Multiplikation.

### 4.2.2 Gauß-Seidel-Verfahren

Wähle  $B = L + D$  (immer noch untere Dreiecksmatrix).

- Auch Einzelschrittverfahren.
- Einfach nacheinander berechenbar, aber nicht parallelisierbar.

### 4.2.3 Unvollständige LR-Zerlegung

Wähle  $B = M \cdot S$ , wobei  $A \approx MS$  „unvollst. LR-Zerlegung“. Die unvollständige LR-Zerlegung ( $A_{j,k} = 0 \Rightarrow (MS)_{j,k} = 0$ ) vermeidet Fill-In, liefert aber kein genaues Resultat.

## 4.3 Konvergenz von Jacobi- und Gauß-Seidel-Verfahren

Ist  $A$  strikt diagonaldominant, so konvergieren sowohl das Jacobi- als auch das Gauß-Seidel-Verfahren für jeden Startwert  $x^0 \in \mathbb{R}^N$  gegen die Lösung  $x_*$  von  $Ax = b$ .

In der Regel konvergiert das Gauß-Seidel-Verfahren schneller als das Jacobi-Verfahren (es ist aber nicht so gut parallelisierbar).



## 4.4 Algorithmus

1. Wähle  $x^0 \in \mathbb{R}^N$ ,  $\epsilon > 0$  und setze  $r^0 = b - Ax^0$ ,  $k = 0$ .
2. Löse  $Bc^k = r^k$  nach  $c^k$ .
  - $x^{k+1} = x^k + c^k$
  - $r^{k+1} = r^k - Ac^k$
3. Falls  $\|r^k\| < \epsilon \|b\|$ , STOP. Ansonsten erhöhe  $k$  und gehe zu Schritt 2.

Merke: Das LGS in Schritt 2 muss leichter zu Lösen sein als  $Ax = b$ , bspw. ist es trivial beim Jacobi-Verfahren, da  $B$  eine Diagonalmatrix ist und einfach beim Gauß-Seidel-Verfahren durch Vorwärtssubstitution.

## 5 Grundwissen

### 5.1 Matrizen

Im folgenden:  $A \in \mathbb{R}^{N \times N}$ .

#### 5.1.1 Symmetrische Matrizen

$$\text{„}A \text{ ist symmetrisch“} \quad (47)$$

$$\Leftrightarrow A = A^\top \quad (48)$$

#### 5.1.2 Reguläre Matrizen

$$\text{„}A \text{ ist regulär“} \quad (49)$$

$$\Leftrightarrow \text{„}A \text{ ist invertierbar“} \quad (50)$$

$$\Leftrightarrow \exists A^{-1} : AA^{-1} = A^{-1}A = I_N \quad (51)$$

#### 5.1.3 Orthogonale Matrizen

#### 5.1.4 Matrixnormen

**Spaltensummennorm** Größte betragliche Summe einer Spalte:

$$\|A\|_1 = \max_{m=1,\dots,N} \sum_{n=1}^N |a_{nm}| \quad (52)$$

**Zeilensummennorm** Größte betragliche Summe einer Zeile:

$$\|A\|_\infty = \max_{n=1,\dots,N} \sum_{m=1}^N |a_{nm}| \quad (53)$$

**Spektralnrm** Wurzel des größten EW von  $A^\top A$ :

$$\|A\|_2 = \sqrt{\max \text{spec}(A^\top A)} \quad (54)$$

### 5.1.5 Eigenwerte

Seien  $v \in \mathbb{R}^N$ ,  $\lambda \in \mathbb{R}$ .  $v$  heißt Eigenvektor zum Eigenwert  $\lambda$  genau dann wenn:

$$Av = \lambda v \tag{55}$$

$A^{-1}$  hat die EW  $\frac{1}{\lambda}$  zu denselben EV  $v$ :

$$Av = \lambda v \Leftrightarrow v = \lambda A^{-1}v \Leftrightarrow A^{-1}v = \frac{1}{\lambda}v \tag{56}$$

$A - \lambda^* I_N$  hat die EW  $\lambda - \lambda^*$  zu denselben EV  $v$ :

$$(A - \lambda^* I_N)v = Av - \lambda^* I_N v = \lambda v - \lambda^* v = (\lambda - \lambda^*)v \tag{57}$$